机器学习
第 3 章　特征工程

——数据决定上限，特征工程决定能否触及上限

2026 年 3 月 17 日

本章题目导览：你将挑战哪些核心问题？

特征工程是机器学习项目中最耗时却最关键的环节——据统计，数据科学家约 60% 的时间花在数据清洗和特征工程上。本章 6 道题覆盖特征工程的所有核心手段：

- **Q3-01（概念框架）**：特征工程的四大内容——选择、转换、构造、降维，各自解决什么问题？
- **Q3-02（特征选择）**：过滤法、包裹法、嵌入法三种特征选择策略的对比与选择场景。
- **Q3-03（数值计算）**：归一化 vs 标准化——公式手算 + 适用场景判断，两者绝对不能混用！
- **Q3-04（类别编码）**：One-hot 编码与 Label Encoding 的选择——什么情况下该用哪种？
- **Q3-05（相关系数）**：皮尔逊 vs 斯皮尔曼相关系数——两者的区别、计算方法与适用条件。
- **Q3-06（PCA 理解）**：主成分分析的直觉、步骤与 sklearn API，以及何时用 PCA。

1　第 3 章　特征工程：让数据说话

先建立一个总感觉：特征工程是什么？

把数据比作一块未经加工的矿石，特征工程就是**提炼矿石的过程**：

- **特征选择**：把矿石里没价值的杂质（无关特征）扔掉；
- **特征转换**：把矿石研磨成粉末（统一量纲、归一化），让不同矿石能放在一起比较；
- **特征构造**：把几块矿石熔炼成新的合金（交叉特征），发现原来分开时看不出的价值；
- **特征降维**：把一百种成分的矿石压缩成几种主要成分的描述，去掉冗余。

Q3-01 特征工程框架：四大内容总览

题目描述：

特征工程（Feature Engineering）是指将原始数据转化为能更好地表达问题本质、从而提升模型性能的特征的过程。它包含四大类工作。

问题：

(1) 填写下表，总结特征工程四大内容：

类别	解决的问题	主要方法	典型 API
特征选择	_____	过滤法、包裹法、嵌入法	_____
特征转换	_____	_____	StandardScaler, MinMaxScaler
特征构造	_____	_____	_____
特征降维	_____	PCA、LDA、t-SNE	_____

(2) 特征工程中有一个重要原则：" 必须在训练集上 `fit`，在所有集合上 `transform`"。解释这条原则的含义，以及违反它会导致什么问题。

(3) 特征工程是否适用于所有机器学习模型？深度学习和传统机器学习在特征工程需求上有什么区别？

来源溯源：[文档第 3 章 3.1–3.2]

参考答案与详细解析

(1) 四大内容填表：

类别	解决的问题	主要方法	典型 API
特征选择	去掉无关/冗余特征，降低维度，防止过拟合	过滤法、包裹法、嵌入法	`SelectKBest`, `RFE`
特征转换	消除量纲差异，改善数据分布	归一化、标准化、对数变换、编码	`StandardScaler`, `MinMaxScaler`
特征构造	挖掘特征间的组合关系，增加信息量	交叉特征、统计特征、时间特征	`PolynomialFeatures`
特征降维	压缩高维特征，去除冗余，可视化	PCA、LDA、t-SNE、自编码器	`PCA`, `TSNE`

(2) fit/transform 原则：

只在训练集上 fit，意味着变换的统计量（如归一化的最大最小值、标准化的均值和标准差）**只从训练数据中计算**，然后用同样的参数对验证集和测试集做 transform。若在全量数据（含测试集）上 fit，测试集的统计信息就" 泄漏" 到了训练过程中（称为**数据泄漏/信息泄漏**），导致测试集上的评估结果过于乐观，高估了模型的真实泛化能力。

(3) 深度学习 vs 传统 ML 的特征工程需求：

传统机器学习（SVM、逻辑回归、随机森林等）**高度依赖特征工程**，人工设计的特征质量直接决定模型上限。深度学习的优势在于能从原始数据（像素、词元）中**自动学习层次化特征表示**，大大减少了对手工特征工程的依赖。但深度学习仍需要：数据预处理（归一化/标准化）、类别编码、处理缺失值等基础转换；且在数据量有限时，手工特征工程仍能显著提升深度模型性能。

Q3-02 特征选择：过滤法、包裹法、嵌入法对比

题目描述：

特征选择是去掉无关特征和冗余特征的过程，有三种主要方法，各有优缺点和适用场景。

问题：

(1) 填写下表，对比三种特征选择方法：

方法	核心思路	优点	缺点/局限
过滤法	用统计指标对特征独立打分，按分数筛选	_____	_____
包裹法	_____	能考虑特征间的交互	_____
嵌入法	_____	_____	依赖特定模型

(2) 低方差过滤法（Variance Threshold）的原理是什么？如果一个特征的方差接近 0，说明什么？给出 sklearn 的使用代码。

(3) 皮尔逊相关系数过滤法中，如果两个特征之间的相关系数绝对值很高（如 $|r| > 0.95$），通常的处理策略是什么？为什么不能两个都保留？

(4) L1 正则化（Lasso）为什么能实现嵌入式特征选择？L1 正则化与 L2 正则化在特征选择能力上有什么本质区别？

来源溯源：[文档第 3 章 3.2.1 特征选择 / 3.3.1–3.3.2]

参考答案与详细解析

(1) 三种方法对比：

方法	核心思路	优点	缺点/局限
过滤法	用统计指标独立评分筛选	计算速度快，与模型无关，可扩展到高维	不考虑特征间交互，可能保留冗余组合
包裹法	用目标模型的性能评估特征子集，搜索最优子集（如 RFE）	能考虑特征间交互，针对具体模型优化	计算代价极高（2^p 种子集），容易过拟合
嵌入法	将特征选择融入模型训练（如 L1 正则化、树模型特征重要性）	兼顾效率和特征交互，与模型一体化	依赖特定模型，不同模型给出的重要性不同

(2) 低方差过滤法：

方差衡量特征的" 变化程度"。方差接近 0 说明该特征在所有样本中几乎取同一个值（如某列全是 1，或某二值列 99% 都是 0）——这样的特征对区分样本**没有任何贡献**，可以直接删除。

```python
from sklearn.feature_selection import VarianceThreshold
selector = VarianceThreshold(threshold=0.01)  # 方差小于0.01的特征被删除
X_selected = selector.fit_transform(X_train)

```

(3) 高相关特征的处理：

两个高度相关的特征本质上携带了**相同的信息**（多重共线性），同时保留不会增加有效信息，反而会：增加模型参数数量（过拟合风险）；在线性模型中导致系数估计不稳定（矩阵近似奇异）。通常保留一个删除另一个，或用 PCA 将两者合并为一个主成分。

(4) L1 vs L2 的特征选择能力：

L1 产生稀疏解的数学原因

L1 正则化在参数空间中等价于在一个" 菱形" 约束区域内优化，损失函数的等高线与菱形的**顶角**（坐标轴上的点）相交概率更高——这些点恰好有许多参数为零，产生**稀疏解**。L2 正则化的约束区域是" 球形"，等高线倾向于在球面光滑处相切，几乎没有权重会精确等于零，只是被压缩得很小——**不产生稀疏解**，因此无法做特征选择，只能做正则化。

Q3-03 归一化 vs 标准化：公式计算 + 场景判断

题目描述：

数值特征的尺度差异会严重影响许多机器学习算法的性能。归一化和标准化是最常用的两种特征缩放方法。

题目数据：某数据集的”年龄”特征，5 个样本值为：$[18, 25, 30, 45, 62]$。

问题：

(1) 写出**归一化**（Min-Max Normalization）的公式，并对上述 5 个值进行归一化计算（保留两位小数）。

(2) 写出**标准化**（Z-score Standardization）的公式，并对上述 5 个值进行标准化计算（保留两位小数）。（提示：均值 $\bar{x} = 36$，标准差 $s \approx 15.94$）

(3) 填写下表，对比两种方法的适用场景：

对比维度	归一化（Min-Max）	标准化（Z-score）
输出范围	_____	均值为 0，标准差为 1，_____（无固定范围）
对异常值敏感性	_____	_____
适合场景	_____	_____
不适合场景	数据有明显异常值时	_____

(4) 决策树和随机森林**不需要**特征缩放，为什么？哪些算法**必须**进行特征缩放？

来源溯源：[文档第 3 章 3.2.2 归一化 / 标准化]

参考答案与详细解析

(1) 归一化计算：

公式：$x' = \dfrac{x - x_{\min}}{x_{\max} - x_{\min}}$，其中 $x_{\min} = 18$，$x_{\max} = 62$，范围 $= 44$。

原始值	计算过程	归一化结果
18	$(18 - 18)/44$	0.00
25	$(25 - 18)/44$	0.16
30	$(30 - 18)/44$	0.27
45	$(45 - 18)/44$	0.61
62	$(62 - 18)/44$	1.00

(2) 标准化计算：

公式：$x' = \dfrac{x - \bar{x}}{s}$，其中 $\bar{x} = 36$，$s \approx 15.94$。

原始值	计算过程	标准化结果
18	$(18-36)/15.94$	-1.13
25	$(25-36)/15.94$	-0.69
30	$(30-36)/15.94$	-0.38
45	$(45-36)/15.94$	$+0.56$
62	$(62-36)/15.94$	$+1.63$

(3) 适用场景对比：

对比维度	归一化	标准化
输出范围	$[0,1]$（固定）	均值 0，标准差 1，无固定范围
异常值敏感性	**高度敏感：**异常值决定 min/max，严重影响其他样本缩放	**相对稳健：**异常值影响均值和标准差，但程度较轻
适合场景	需要输出在固定区间（如神经网络激活函数）；数据分布未知但已知边界范围	数据近似正态分布；不知道数据范围；有异常值但分布合理
不适合场景	数据有明显异常值时	需要严格保持 $[0,1]$ 输出范围时（如图像像素）

(4) 决策树不需要缩放的原因 + 必须缩放的算法：

决策树的分裂判断基于**特征阈值**（"年龄 >30？"），是对单个特征的有序比较，不涉及特征之间的距离计算或线性组合——特征的绝对数值大小不影响分裂结果，只有相对排序重要。

必须进行特征缩放的算法

必须缩放：KNN（基于距离）、SVM（基于间隔，距离度量）、逻辑回归/线性回归（梯度更新步长受特征量纲影响）、神经网络（梯度下降收敛速度受量纲影响）、PCA（基于方差/协方差，量纲不一致会使方差大的特征主导主成分）、K-means（基于距离）。

不需要缩放：决策树、随机森林、XGBoost/LightGBM（基于排序/分裂，量纲不影响结果）。

Q3-04 类别变量编码：One-hot vs Label Encoding

题目描述：

机器学习模型只能处理数值，但许多特征是类别型的（如" 城市"" 颜色"" 学历"）。如何将类别转为数值，是特征工程的重要问题。

问题：

(1) **Label Encoding**（标签编码）将每个类别映射为一个整数（如红 =0，绿 =1，蓝 =2）。这种方式有什么潜在问题？在什么情况下是合理的？

(2) **One-hot Encoding**（独热编码）为什么能解决 Label Encoding 的问题？对" 颜色" 特征（红/绿/蓝）做 One-hot 编码后，数据会变成什么形式？

(3) 当类别特征的取值种数非常多（如城市有 3000 个），使用 One-hot 编码会遇到什么问题（维度灾难、稀疏矩阵）？有哪些替代方案？

(4) 填写下表，总结各编码方式的适用场景：

编码方式	适用场景	注意事项
Label Encoding	_____	不能用于无序类别的线性模型
One-hot Encoding	_____	_____
Target Encoding	_____	_____

来源溯源：[文档第 3 章 3.2.2 类别变量的编码]

参考答案与详细解析

(1) Label Encoding 的问题：

整数编码隐含了**大小关系**（红 =0 < 绿 =1 < 蓝 =2），而颜色之间本无大小。线性模型会把这个人为设定的顺序解读为真实的数值关系（认为" 蓝比红大 2 倍"），导致错误的决策边界。**合理使用场景：**有内在顺序的类别特征（学历：小学 =0, 初中 =1, 高中 =2, 大学 =3）——这些类别确实有大小/优劣关系，Label Encoding 的整数顺序与真实语义一致。

(2) One-hot 编码：

One-hot 为每个类别创建独立的二进制列，完全消除了类别之间的假设大小关系：

$$\text{红} \to [1,0,0], \quad \text{绿} \to [0,1,0], \quad \text{蓝} \to [0,0,1]$$

三列的任意两列内积为 0，说明三个类别在模型眼中" 等距"，不存在任何大小偏差。

(3) 高基数类别的问题与替代方案：

3000 个城市做 One-hot 会产生 3000 列，绝大多数位置为 0（稀疏矩阵），大幅增加计算量和内存消耗，且每个城市训练样本很少（过拟合风险）。替代方案：**Target Encoding**（用该类别的目标变量均值替换）；**频率编码**（用该类别出现的频率替换）；**嵌入编码**（Embedding，用低维稠密向量表示，适合深度学习）；**分组/层级编码**（如城市 → 省 → 地区，用更粗粒度）。

(4) 编码方式适用场景：

编码方式	适用场景	注意事项
Label Encoding	有序类别特征（学历、评级）；树模型（对顺序不敏感）	不能用于无序类别的线性模型/SVM
One-hot Encoding	无序类别，取值种数较少（< 几十个）；线性模型、SVM、神经网络	存在多重共线性（哑变量陷阱），通常删掉一列；高基数时维度爆炸
Target Encoding	高基数类别特征；梯度提升树	存在数据泄漏风险，需用交叉验证方式编码

Q3-05 相关系数：皮尔逊 vs 斯皮尔曼

题目描述：

相关系数是衡量两个变量之间线性/单调关系强度的统计量，是特征选择中最常用的过滤指标之一。

问题：

(1) 皮尔逊相关系数的公式是：

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2} \cdot \sqrt{\sum_i (y_i - \bar{y})^2}}$$

给定数据：$x = [1, 2, 3, 4, 5]$，$y = [2, 4, 6, 8, 10]$，手动计算 r（$\bar{x} = 3, \bar{y} = 6$）。

(2) 斯皮尔曼相关系数的核心思路是什么？它与皮尔逊相关系数的**适用条件**有什么区别？

(3) 下面几种场景，分别应该用皮尔逊还是斯皮尔曼相关系数？

A. 研究”学习时长（小时）”与”考试分数（0–100 分）”的关系，两个变量近似正态分布

B. 研究”用户评分（1–5 星）”与”复购次数”的关系，评分是离散有序变量

C. 研究”收入”与”幸福感（1–10 分）”，收入数据有严重右偏（少数超高收入）

(4) 相关系数为 0 说明两个变量**一定没有关系**吗？举一个反例。

来源溯源：[文档第 3 章 3.3.2 相关系数法]

参考答案与详细解析

(1) 皮尔逊相关系数计算：

$\bar{x} = 3, \bar{y} = 6$，各差值：$x - \bar{x} = [-2, -1, 0, 1, 2]$，$y - \bar{y} = [-4, -2, 0, 2, 4]$

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = (-2)(-4) + (-1)(-2) + (0)(0) + (1)(2) + (2)(4) = 8 + 2 + 0 + 2 + 8 = 20$$

$$\sqrt{\sum (x_i - \bar{x})^2} = \sqrt{4 + 1 + 0 + 1 + 4} = \sqrt{10}, \quad \sqrt{\sum (y_i - \bar{y})^2} = \sqrt{16 + 4 + 0 + 4 + 16} = \sqrt{40}$$

$$r = \frac{20}{\sqrt{10} \times \sqrt{40}} = \frac{20}{\sqrt{400}} = \frac{20}{20} = \boxed{1.0}$$

完全线性相关（$y = 2x$），符合预期。

(2) 斯皮尔曼 vs 皮尔逊：

斯皮尔曼相关系数先将两个变量**各自转为秩（排名）**，然后对秩计算皮尔逊相关系数。它衡量的是**单调关系**（无论线性还是非线性的单调），而皮尔逊只衡量**线性关系**。适用条件：皮尔逊要求数据近似正态分布、无显著异常值、关系为线性；斯皮尔曼无分布假设，对异常值更鲁棒，适合有序分类变量或存在异常值的连续变量。

(3) 场景选择：

- **A → 皮尔逊**：两个变量近似正态，关系线性，皮尔逊的假设完全满足。
- **B → 斯皮尔曼**：评分是离散有序变量（1–5 星），不满足连续/正态假设，斯皮尔曼更合适。
- **C → 斯皮尔曼**：收入严重右偏（异常值多），皮尔逊会被极端值严重影响，斯皮尔曼基于秩，对异常值鲁棒。

(4) 相关系数为 0 不代表无关系：

皮尔逊相关系数为 0 只说明**线性关系不显著**，但可能存在非线性关系。反例：$x = [-2, -1, 0, 1, 2]$，$y = [4, 1, 0, 1, 4]$（即 $y = x^2$）。由于 y 关于 $x = 0$ 完全对称，皮尔逊相关系数精确为 0，但两者有完美的二次（非线性）关系。这正是斯皮尔曼等非参数方法、以及互信息等非线性关系度量的价值所在。

Q3-06 PCA：主成分分析的直觉、步骤与 API

题目描述：

主成分分析（PCA）是最经典的线性降维方法。在特征工程中，PCA 既可用于去除冗余特征，也可用于数据可视化（将高维数据降到 2–3 维展示）。

问题：

(1) PCA 的核心目标是什么？”主成分”（Principal Component）在几何上是什么含义？

(2) PCA 算法的步骤（用 SVD 实现）依次是： 中心化， SVD 分解， 选取前 k 个奇异向量， 投影。解释每步的目的，并说明为什么第 步中心化是必须的。

(3) 如何决定保留**多少个主成分**（选择 k 的方法）？写出”解释方差比例”的公式，并说明通常选择的阈值（如 95%）意味着什么。

(4) 写出用 sklearn 对鸢尾花数据集（4 维）降至 2 维的完整代码，并打印保留的方差比例。

```python
from sklearn.decomposition import PCA
from sklearn.datasets import load_iris
import numpy as np

iris = load_iris()
X = iris.data   # shape: (150, 4)

# 请补全代码：标准化 -> PCA降维 -> 输出方差比例

```

(5) PCA 降维后得到的新特征（主成分）是否具有业务含义？这对模型的可解释性有什么影响？

来源溯源：[文档第 3 章 3.2.4 / 3.3.3 主成分分析（PCA）]

参考答案与详细解析

(1) PCA 核心目标与主成分含义：

PCA 的目标是找到一组新的正交坐标轴，使数据在这些轴上的**投影方差最大**（信息保留最多），同时各轴之间不相关（去除冗余）。主成分在几何上是数据点云中**方差最大的方向**——第一主成分是数据变化最剧烈的方向，第二主成分是与第一主成分垂直的、方差次大的方向，以此类推。

(2) 各步目的：

- **中心化**：减去均值，使数据以原点为中心。若不中心化，SVD 的第一个奇异向量会指向数据均值方向，而非真正的最大方差方向。
- **SVD 分解**：将中心化矩阵分解为 $X_c = U\Sigma V^T$，右奇异矩阵 V 的列就是主成分方向。
- **选取前 k 个奇异向量**：保留方差贡献最大的 k 个主方向，舍弃信息量小的维度。
- **投影**：$Z = X_c V_k$，将数据从原始空间投影到 k 维主成分空间。

(3) 选择 k 的方法：

$$\text{Explained Variance Ratio}(k) = \frac{\sum_{i=1}^{k} \sigma_i^2}{\sum_{i=1}^{r} \sigma_i^2}$$

选择使该比值达到 95%（或 90%、99%）的最小 k，意味着保留 k 个主成分后，原始数据 95% 的变异信息被保留，仅丢失 5% 的" 次要信息"（通常是噪声）。

(4) 完整代码：

```python
from sklearn.decomposition import PCA
from sklearn.datasets import load_iris
from sklearn.preprocessing import StandardScaler

iris = load_iris()
X = iris.data

# 先标准化（PCA对量纲敏感，必须标准化）
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# PCA降至2维
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)

print(f"降维后形状：{X_pca.shape}")
print(f"各主成分解释方差比例：{pca.explained_variance_ratio_}")
print(f"前2个主成分累计解释方差：{pca.explained_variance_ratio_.sum():.2%}")

```

(5) 主成分的可解释性：

PCA 的主成分是原始特征的**线性组合**，通常**不具有直接的业务含义**（如"PC1 = 0.52× 花萼长 − 0.37× 花瓣宽 + ...”，很难直接解释是什么），这使得基于 PCA 的模型可解释性较差，在需要向业务方解释"

为什么这样预测” 的场景（如信贷审批）中慎用。PCA 更适合探索性分析、可视化、或将高维特征压缩后作为下游模型的输入（不需要解释特征含义的场景）。

2 本章小结

- **fit-transform 原则铁律**：只在训练集 fit，再 transform 所有集合——违反会导致数据泄漏。
- **归一化 vs 标准化**：有异常值用标准化；需要固定范围用归一化；决策树/随机森林不需要缩放。
- **类别编码**：有序 → Label Encoding；无序且低基数 → One-hot；高基数 → Target Encoding 或 Embedding。
- **特征选择三方法**：过滤法快但忽略交互；包裹法好但慢；嵌入法（L1/树模型）兼顾效率与效果。
- **PCA 的代价**：降维压缩信息，失去可解释性——只在确实需要降维时使用，不是万能的预处理步骤。