机器学习
第 4 章　模型评估和模型选择

——如何知道模型学得好不好？如何让它学得更好？

2026 年 3 月 17 日

本章题目导览：你将挑战哪些核心问题？

本章是机器学习的”质量控制”核心章节——没有评估，就不知道模型在现实中会不会失败。本章 8 道题覆盖从损失函数到梯度下降的完整评估与优化体系：

- **Q4-01（损失函数）**：四种损失函数的公式、性质与适用场景——为什么不同任务用不同的损失？
- **Q4-02（欠拟合/过拟合）**：识别、诊断、解决——偏差-方差权衡是什么？
- **Q4-03（正则化计算）**：L1/L2/ElasticNet 的公式、几何直觉与超参数作用，手动计算正则化项。
- **Q4-04（交叉验证）**：Hold-Out、k 折、LOO 三种策略的优缺点与适用场景。
- **Q4-05（梯度下降推导）**：BGD/SGD/MBGD 的对比，以及梯度下降一步迭代的手动计算。
- **Q4-06（回归评估指标）**：MAE/MSE/RMSE/R^2 的公式计算与含义辨析。
- **Q4-07（分类评估指标）**：混淆矩阵、准确率/精确率/召回率/F1 的计算，类别不平衡下的指标选择。
- **Q4-08（ROC/AUC）**：ROC 曲线的绘制原理、AUC 的含义，以及 ROC vs PR 曲线的选择。

1　第 4 章　模型评估和模型选择

先建立一个总感觉：评估是什么？为什么重要？

模型训练完之后，我们面临两个关键问题：**它学得好吗？**（评估）**怎么让它学得更好？**（选择与优化）。没有评估就没有方向——就像考试不公布分数，学生不知道哪里错了，怎么改进？

评估的难点在于：我们真正关心的是模型在**未知新数据**上的表现，但手里只有有限的历史数据。所有评估方法（交叉验证、测试集）都是在用有限数据**估计**这个”真实表现”。

Q4-01 损失函数：四种损失的公式与适用场景

题目描述：

损失函数量化了模型预测与真实值之间的差距，是策略的核心。不同任务对损失函数有不同的要求。

问题：

(1) 填写下表，对比四种常见损失函数：

损失函数	公式	适用任务	主要特点
0-1 损失	$L = \mathbb{1}[\hat{y} \neq y]$	_____	_____
平方损失（MSE）	_____	_____	对异常值敏感
绝对损失（MAE）	_____	_____	_____
对数似然损失	$-[y \log \hat{p} + (1 - y) \log(1 - \hat{p})]$	_____	_____

(2) 0-1 损失函数为什么**不能用梯度下降**来优化？实际分类任务中为什么用对数损失来替代它？

(3) 平方损失和绝对损失都可以用于回归，但有一个关键差异：异常值（Outlier）存在时，哪种损失函数更鲁棒？从数学角度解释原因。

(4) 写出多分类任务的交叉熵损失公式（Softmax Cross-Entropy），并说明其与二分类对数损失的关系。

来源溯源：[文档第 4 章 4.1 损失函数]

参考答案与详细解析

(1) 四种损失对比：

损失函数	公式	适用任务	主要特点
0-1 损失	$\mathbb{1}[\hat{y} \neq y]$	分类	不可微，无法梯度优化
平方损失	$(\hat{y} - y)^2$	回归	处处可微，对异常值极敏感
绝对损失	$\lvert\hat{y} - y\rvert$	回归	在 0 处不可微，对异常值鲁棒
对数似然损失	$-[y \log \hat{p} + (1 - y) \log(1 - \hat{p})]$	二分类	概率化损失，凸函数，梯度平滑

(2) 0-1 损失不可梯度优化：

0-1 损失是阶跃函数：在正确预测时梯度为 0，在错误预测时梯度无定义（不连续跳变）——无法计算有意义的梯度方向，梯度下降无从下手。对数损失是 0-1 损失的**凸连续可微上界**：当预测正确时损失

接近 0，预测错误时损失趋向无穷，惩罚了”高置信度的错误预测”，同时处处可微，梯度可以平滑地传播。

(3) 对异常值的鲁棒性：

MAE（绝对损失）更鲁棒。平方损失对误差做平方放大——一个误差为 10 的异常点产生损失 100，贡献的梯度与误差成正比，会严重”扭曲”模型参数去迁就这个异常点。MAE 的梯度是恒定的 ± 1（与误差大小无关），异常点的影响被限制在固定范围内，不会因为误差大而主导整个优化方向。

(4) 多分类交叉熵：

$$L = -\sum_{c=1}^{C} y_c \log \hat{p}_c$$

其中 $\hat{p}_c = \mathrm{softmax}(z_c)$，$y_c$ 是 one-hot 标签。当 $C = 2$ 时，$y_1 = y$，$y_2 = 1 - y$，退化为二分类对数损失，两者是统一框架下的特例关系。

Q4-02 欠拟合与过拟合：诊断、原因与解决

题目描述：

欠拟合和过拟合是机器学习中最核心的两个问题，理解它们的本质是选择合适模型和正则化策略的基础。

问题：

(1) 解释**偏差（Bias）**和**方差（Variance）**的含义，并填写下表：

	欠拟合	过拟合	理想模型
偏差	_____	_____	低
方差	_____	_____	低
训练集误差	_____	_____	低
测试集误差	_____	_____	低（接近训练误差）
产生原因	_____	_____	—

(2) **诊断方法**：如何通过”训练误差”和”验证误差”的大小关系来判断模型处于欠拟合还是过拟合状态？

(3) **解决欠拟合的方法**（至少 3 种）；**解决过拟合的方法**（至少 4 种）。

(4) 学习曲线（Learning Curve）是一种常用的诊断工具，横轴是训练样本数量，纵轴是误差。描述欠拟合和过拟合模型各自的学习曲线形状特征。

来源溯源：[文档第 4 章 4.3 欠拟合与过拟合]

参考答案与详细解析

(1) 偏差-方差表格：

	欠拟合	过拟合	理想模型
偏差	高（系统性错误）	低	低
方差	低	高（对数据敏感）	低
训练集误差	高	很低（近乎为 0）	低
测试集误差	高（与训练误差相近）	很高（远大于训练误差）	低
产生原因	模型太简单/特征不足	模型太复杂/数据太少	—

(2) 诊断方法：

- 训练误差高 + 验证误差高且两者接近 → **欠拟合**（高偏差）
- 训练误差低 + 验证误差远高于训练误差 → **过拟合**（高方差）
- 训练误差低 + 验证误差也低且接近 → **理想状态**

(3) 解决方案：

- **欠拟合**：增加模型复杂度（更深的树、更多层神经网络）；增加特征（特征工程构造新特征）；减少正则化强度；训练更长时间（增加迭代轮数）。
- **过拟合**：增加训练数据量；减少模型复杂度（降低树深/减少层数）；正则化（L1/L2/Dropout）；数据增强；早停（Early Stopping）；交叉验证选超参数。

(4) 学习曲线特征：

学习曲线诊断

欠拟合：训练误差和验证误差都**很高**，随数据量增加两者缓慢下降但最终趋于一个较高的值，且两者间隙小——增加数据无法根本解决问题，需要改进模型。

过拟合：训练误差**很低**，验证误差**很高**，两者间隙很大。随数据量增加，验证误差下降，训练误差上升，两者逐渐靠拢——增加数据有效，或添加正则化。

Q4-03 正则化：L1/L2/ElasticNet 的公式与手算

题目描述：

正则化通过在损失函数中添加惩罚项来限制模型复杂度，防止过拟合。三种主要正则化方法各有特点。

问题：

(1) 写出加入正则化后的目标函数一般形式（以线性模型为例），并说明正则化系数 λ 的作用。

(2) 设模型参数 $\mathbf{w} = [2, -1, 0.5, -3]$，$\lambda = 0.1$，分别计算：

a. L1 正则化项 $R_1 = \lambda\|\mathbf{w}\|_1$

b. L2 正则化项 $R_2 = \lambda\|\mathbf{w}\|_2^2$

c. ElasticNet 正则化项（$\alpha = 0.5$，即 L1 和 L2 各半权重）

(3) 填写下表，对比三种正则化方法：

方法	数学形式	对参数的作用	典型使用场景
L1（Lasso）	$\lambda \sum \lvert w_j \rvert$	将部分参数_____	_____
L2（Ridge）	_____	将参数_____	_____
ElasticNet	_____	_____	_____

(4) 参数 λ 值越大，模型会发生什么变化（过拟合方向还是欠拟合方向）？$\lambda = 0$ 和 $\lambda \to \infty$ 各对应什么极端情况？

来源溯源：[文档第 4 章 4.4 正则化]

参考答案与详细解析

(1) 正则化目标函数：

$$J(\mathbf{w}) = \underbrace{\frac{1}{n}\sum_{i=1}^{n} L(f(x_i), y_i)}_{\text{经验损失}} + \underbrace{\lambda R(\mathbf{w})}_{\text{正则化项}}$$

$\lambda > 0$ 控制正则化强度：λ 越大，对参数幅度的惩罚越重，模型参数被压缩得越小，模型越简单（偏向欠拟合）；λ 越小，正则化影响越弱，模型可以更自由地拟合数据。

(2) 手动计算（$\mathbf{w} = [2, -1, 0.5, -3], \lambda = 0.1$）：

a. $R_1 = 0.1 \times (|2| + |-1| + |0.5| + |-3|) = 0.1 \times 6.5 = \mathbf{0.65}$

b. $R_2 = 0.1 \times (4 + 1 + 0.25 + 9) = 0.1 \times 14.25 = \mathbf{1.425}$

c. ElasticNet（$\alpha = 0.5$）：$R = \lambda[\alpha\|\mathbf{w}\|_1 + (1-\alpha)\|\mathbf{w}\|_2^2] = 0.1[0.5 \times 6.5 + 0.5 \times 14.25] = 0.1 \times 10.375 = \mathbf{1.0375}$

(3) 三种正则化对比：

方法	数学形式	对参数的作用	典型场景
L1	$\lambda \sum \lvert w_j \rvert$	将部分参数**压缩为精确的零**（稀疏）	特征选择、高维稀疏场景
L2	$\lambda \sum w_j^2$	将参数**均匀压小但不为零**	多重共线性、大多数回归场景
ElasticNet	$\lambda[\alpha \lVert \mathbf{w} \rVert_1 + (1-\alpha) \lVert \mathbf{w} \rVert_2^2]$	兼具稀疏性和稳定性	特征间高度相关且数量多的场景

(4) λ 的极端情况：

λ 越大，正则化项主导目标函数，模型参数被强行压向 0，拟合能力减弱，**偏向欠拟合**。$\lambda = 0$：无正则化，模型可自由拟合，**退化为无约束的普通回归**（过拟合风险最高）。$\lambda \to \infty$：正则化项极大，所有参数趋向 0（L1）或趋向 0（L2），模型**退化为只输出均值的常数预测**（严重欠拟合）。

Q4-04 交叉验证：Hold-Out、k 折、LOO 对比

题目描述：

交叉验证是通过合理划分数据来可靠估计模型泛化误差的方法，有三种主要策略。

问题：

(1) 填写下表对比三种交叉验证策略：

方法	核心思路	优点	缺点/适用条件
Hold-Out	一次性划分训练/验证集	_____	_____
k 折交叉验证	_____	_____	_____
LOO	_____	_____	_____

(2) k 折交叉验证中，k 一般取多少？k 取得太大（如 $k = n$，退化为 LOO）和太小（如 $k = 2$）分别有什么问题？

(3) 写出 sklearn 实现 5 折交叉验证的核心代码，并说明 `cross_val_score` 返回的是什么。

(4) 分层 k 折交叉验证（Stratified k-Fold）和普通 k 折有什么区别？在什么情况下必须用分层交叉验证？

来源溯源：[文档第 4 章 4.5 交叉验证]

参考答案与详细解析

(1) 三种策略对比：

方法	核心思路	优点	缺点/适用条件
Hold-Out	固定比例划分，训练/验证各用一次	速度快，实现简单	评估结果依赖随机划分，方差大；需要数据量充足
k 折 CV	数据分 k 份，轮流用 1 份验证、k-1 份训练，取均值	充分利用数据，评估更稳定可靠	训练 k 次，计算代价高；k 的选择影响偏差-方差
LOO	每次留 1 个样本验证，其余全部训练	最充分利用数据，接近无偏估计	计算代价极高（训练 n 次）；评估方差高，只适合极小数据集

(2) k 值的选择：

通常取 $k = 5$ 或 $k = 10$（工业经验最佳平衡点）。k 太大（接近 LOO）：每次训练集更多、验证集更小，偏差低但评估方差高，计算代价极大。k 太小（如 $k = 2$）：每次训练集只有一半数据，模型欠拟合，评估偏差大。

(3) sklearn 5 折交叉验证代码：

```python
from sklearn.model_selection import cross_val_score
from sklearn.linear_model import LogisticRegression

model = LogisticRegression()
scores = cross_val_score(model, X, y, cv=5, scoring='accuracy')
print(f"5折CV各折准确率: {scores}")
print(f"均值 ± 标准差: {scores.mean():.3f} ± {scores.std():.3f}")

```

`cross_val_score` 返回一个长度为 k 的数组，每个元素是对应折验证集上的评估分数。取均值作为模型的最终估计性能，标准差衡量估计的稳定性。

(4) 分层 k 折：

分层 k 折在划分时**保持每折中各类别比例与原始数据一致**（如原始数据正负比例 1:9，每折也保持 1:9）。当数据类别极不平衡时必须使用——若不分层，某折可能完全没有少数类样本，导致该折评估失真（如准确率虚高）。

Q4-05 梯度下降：推导 + 手动计算一步迭代

题目描述：

梯度下降是最核心的参数优化算法，三种变体各有取舍。本题通过手动计算加深理解。

问题：

(1) 梯度下降的参数更新公式是 $\theta \leftarrow \theta - \eta \nabla_\theta J(\theta)$。解释每个符号的含义，并说明为什么是" 负梯度" 方向。

(2) 设损失函数为 $J(w) = (w-3)^2$，当前参数 $w_0 = 0$，学习率 $\eta = 0.1$。手动执行 3 步梯度下降，填写下表：

步骤	当前 w	梯度 $\frac{dJ}{dw}$	更新量 $\eta \cdot$ 梯度	新 w
1	0	__	__	__
2	__	__	__	__
3	__	__	__	__

(3) 填写下表，对比三种梯度下降变体：

变体	每次用多少数据	收敛稳定性	适用场景
BGD	_____	_____	_____
SGD	_____	_____	_____
MBGD	_____	_____	_____

(4) 学习率 η 过大和过小分别会导致什么问题？如何选择合适的学习率？

来源溯源：[文档第 4 章 4.6.2 梯度下降法]

参考答案与详细解析

(1) 公式符号含义：

θ：模型参数；η：学习率（步长大小）；$\nabla_\theta J(\theta)$：损失函数对参数的梯度，指向损失**上升最快**的方向。取**负梯度**方向（$-\nabla J$）是因为我们要**最小化**损失，沿梯度反方向走能最快减小损失值——爬山时反向走就是下山。

(2) 手动三步迭代（$J(w) = (w-3)^2$，梯度 $\frac{dJ}{dw} = 2(w-3)$）：

步骤	当前 w	梯度 $2(w-3)$	更新量 $0.1\times$ 梯度	新 w
1	0	-6	-0.6	0.6
2	0.6	-4.8	-0.48	1.08
3	1.08	-3.84	-0.384	1.464

最优解为 $w^* = 3$，可见每步都在向 3 靠近（以 0.8 的比例收缩剩余距离）。

(3) 三种变体对比：

变体	每次用多少数据	收敛稳定性	适用场景
BGD	全量数据	稳定，单调收敛	数据量小，内存足够；凸优化问题
SGD	1 个样本	不稳定，震荡	在线学习；超大规模数据集
MBGD	mini-batch（32/64/128）	较稳定，可并行	**深度学习最常用**；GPU 并行加速

(4) 学习率选择：

η 过大：步长太大，可能越过最优点，在谷底两侧来回震荡甚至发散（损失不降反升）。η 过小：收敛极慢，需要大量迭代；容易陷入局部极小值或鞍点。**选择策略：**使用学习率调度（初始较大，随训练衰减）；网格搜索或学习率预热（Warm-up）；使用自适应学习率优化器（Adam、AdaGrad）自动调节每个参数的学习率。

Q4-06 回归评估指标：MAE/MSE/RMSE/R^2 手动计算

题目描述：

设某回归模型对 5 个样本的预测结果如下：

样本	真实值 y_i	预测值 $\hat{y}_i$	误差 $e_i = \hat{y}_i - y_i$
1	10	12	$+2$
2	20	18	-2
3	15	15	0
4	25	30	$+5$
5	30	27	-3

问题：

(1) 计算 **MAE**（平均绝对误差）。

(2) 计算 **MSE**（均方误差）和 **RMSE**（均方根误差）。

(3) 计算 $\mathbf{R^2}$（决定系数）。（提示：$\bar{y} = 20$，$\text{SS_tot} = \sum(y_i - \bar{y})^2$，$\text{SS_res} = \sum(y_i - \hat{y}_i)^2$）

(4) 填写下表，说明四个指标各自的含义与优缺点：

指标	含义	优缺点	取值范围
MAE	_____	_____	__
RMSE	_____	_____	__
R^2	_____	_____	$(-\infty, 1]$

来源溯源：[文档第 4 章 4.7.1 回归模型评价指标]

参考答案与详细解析

(1) MAE：

$$\text{MAE} = \frac{1}{5}(|2| + |-2| + |0| + |5| + |-3|) = \frac{2+2+0+5+3}{5} = \frac{12}{5} = \mathbf{2.4}$$

(2) MSE 和 RMSE：

$$\text{MSE} = \frac{1}{5}(4+4+0+25+9) = \frac{42}{5} = \mathbf{8.4}$$

$$\text{RMSE} = \sqrt{8.4} \approx \mathbf{2.898}$$

(3) R^2：

$\bar{y} = 20$，各真实值与均值之差：$(10-20)^2 + (20-20)^2 + (15-20)^2 + (25-20)^2 + (30-20)^2 = 100 + 0 + 25 + 25 + 100 = 250$

$\text{SS_tot} = 250$，$\text{SS_res} = 4 + 4 + 0 + 25 + 9 = 42$

$$R^2 = 1 - \frac{\text{SS_res}}{\text{SS_tot}} = 1 - \frac{42}{250} = 1 - 0.168 = \mathbf{0.832}$$

说明该模型解释了目标变量 83.2% 的方差。

(4) 指标含义与优缺点：

指标	含义	优缺点	取值范围
MAE	预测误差绝对值的均值，与目标变量同量纲	直观易解释，对异常值鲁棒；但不可微（绝对值在 0 处）	$[0, +\infty)$
RMSE	预测误差平方均值的开方，与目标变量同量纲	对大误差惩罚更重，可微；对异常值敏感	$[0, +\infty)$
R^2	模型解释了目标变量多少比例的方差（1= 完美，0= 仅预测均值）	无量纲，便于不同数据集比较；可为负（模型差于均值预测）	$(-\infty, 1]$

Q4-07 分类评估指标：混淆矩阵到 F1 分数

题目描述：

某二分类模型（预测是否患病）在测试集上的预测结果如下：

	预测为正（患病）	预测为负（未患病）
实际为正（患病）	TP = 40	FN = 10
实际为负（未患病）	FP = 20	TN = 130

问题：

(1) 根据上表计算：准确率（Accuracy）、精确率（Precision）、召回率（Recall）、F1 分数。（保留两位小数）

(2) 在医疗诊断场景中，**漏诊**（FN）和**误诊**（FP）哪个危害更大？基于此，应该优化精确率还是召回率？

(3) F1 分数是精确率和召回率的**调和平均**而非算术平均，为什么？调和平均有什么特性使它更适合这个场景？

(4) 若将分类阈值从 0.5 调低为 0.3（更容易判定为正类），精确率和召回率会如何变化？（定性描述，不需要数值计算）

来源溯源：[文档第 4 章 4.7.2 分类模型评价指标]

参考答案与详细解析

(1) 各指标计算：

总样本数 $= 40 + 10 + 20 + 130 = 200$

$$\text{Accuracy} = \frac{TP + TN}{n} = \frac{40 + 130}{200} = \frac{170}{200} = \mathbf{0.85}$$

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{40}{40 + 20} = \frac{40}{60} \approx \mathbf{0.67}$$

$$\text{Recall} = \frac{TP}{TP+FN} = \frac{40}{40+10} = \frac{40}{50} = \mathbf{0.80}$$

$$\text{F1} = \frac{2 \times \text{P} \times \text{R}}{\text{P}+\text{R}} = \frac{2 \times 0.67 \times 0.80}{0.67+0.80} = \frac{1.072}{1.47} \approx \mathbf{0.73}$$

(2) 医疗场景中优化目标：

漏诊（FN，患病却被判为未患病）危害更大——患者错过治疗时机，可能危及生命。误诊（FP，未患病被判为患病）虽然不好，但可通过进一步检查纠正，危害相对可控。因此应**优化召回率（Recall）**，尽量找出所有真实患者，宁可多些误报，不可漏掉真正患者。

(3) 调和平均 vs 算术平均：

调和平均 $H = \frac{2PR}{P+R}$ 的特性：当 P 和 R 差距很大时，调和平均会被**较小的那个拉低**（比算术平均更低）。例如 P=0.99, R=0.01，算术平均 $= 0.5$（看起来还不错），调和平均 ≈ 0.02（真实反映了模型几乎失效）。这使 F1 不能通过”一好一坏”来”蒙混过关”，必须两者都高才能有高 F1——更准确地反映模型在精确率和召回率上的综合表现。

(4) 阈值降低的影响：

阈值降低 → 更多样本被预测为正类 → TP 增加（更多真正患者被识别）、FP 也增加（更多健康人被误判为患病）、FN 减少。结果：**召回率上升**（分母 TP+FN 中，FN 减少），**精确率下降**（分母 TP+FP 中，FP 增加）。精确率-召回率之间存在权衡（Precision-Recall Trade-off）。

Q4-08 ROC 曲线与 AUC：原理、绘制与解读

题目描述：

ROC 曲线（Receiver Operating Characteristic）是评估二分类器性能的重要工具，AUC（Area Under Curve）是其综合指标。

问题：

(1) ROC 曲线的横轴和纵轴分别是什么？写出两者的公式，并说明”完美分类器”和”随机猜测分类器”在 ROC 图上各对应什么形状。

(2) AUC 的取值范围是什么？AUC $= 0.5$、AUC $= 1.0$、AUC < 0.5 各代表什么含义？

(3) ROC 曲线是如何随分类阈值变化而描绘出来的？（即从阈值最高到最低，点如何从 ROC 图的左下角移动到右上角）

(4) 在类别严重不平衡（正负比例 1:99）的情况下，ROC-AUC 和 PR-AUC（Precision-Recall 曲线下面积）哪个更能反映模型真实性能？为什么？

来源溯源：[文档第 4 章 4.7.2 ROC 曲线 / AUC 值]

参考答案与详细解析

(1) ROC 轴与特殊分类器：

- 横轴：**FPR（False Positive Rate）** $= \dfrac{FP}{FP+TN}$（假阳性率，负样本中被错判为正的比例）
- 纵轴：**TPR（True Positive Rate/Recall）** $= \dfrac{TP}{TP+FN}$（真阳性率，正样本中被正确识别的比例）

- **完美分类器**：ROC 曲线经过 $(0,0) \to (0,1) \to (1,1)$，即左上角折线，AUC $= 1.0$。
- **随机猜测**：ROC 曲线是从 $(0,0)$ 到 $(1,1)$ 的对角线，AUC $= 0.5$。

(2) AUC 含义：

AUC $\in [0,1]$：AUC $= 1.0$：完美分类，所有正负样本完全可分；AUC $= 0.5$：等同于随机猜测，模型无判别力；AUC < 0.5：比随机猜测还差（如果取反预测反而好于 0.5）。直觉解释：AUC 等于**随机取一个正样本和一个负样本，正样本预测概率高于负样本的概率**——直接量化了模型的" 排序能力"。

(3) ROC 曲线的绘制原理：

从**阈值最高（仅最高置信度的正样本被预测为正）开始**，此时 TP 和 FP 都接近 0，点在 $(0,0)$ 附近。随着阈值降低，越来越多的样本被预测为正：每遇到一个真正正样本（TP++），点沿**纵轴方向上移**；每遇到一个真正负样本（FP++），点沿**横轴方向右移**。最终阈值降到最低时，所有样本都被预测为正，TP 和 FP 均最大，点到达 $(1,1)$。

(4) 类别不平衡下的指标选择：

严重不平衡时应用 PR-AUC

ROC-AUC 在严重不平衡时**过于乐观**：分母 TN（大量负样本）使 FPR 很小，即使 FP 数量不少，FPR 也可能看起来很低，给出虚假高 AUC。而 PR 曲线的精确率分母是 TP+FP（预测为正的样本），不受大量负样本影响，能更真实地反映模型在少数正类上的表现——PR-AUC 更适合不平衡数据的评估。

2 本章小结

- **损失函数决定优化方向**：回归用 MSE/MAE；二分类用对数损失；多分类用交叉熵。有异常值用 MAE，否则 MSE 更常见。
- **欠拟合/过拟合的诊断核心**：看训练误差和验证误差的关系——都高是欠拟合，训练低验证高是过拟合。
- **正则化三兄弟**：L1 稀疏（特征选择）；L2 均匀压缩（稳定）；ElasticNet 兼顾两者。
- **梯度下降实战**：深度学习用 MBGD（mini-batch）+ Adam；学习率太大发散，太小收敛慢。
- **分类指标的权衡**：类别平衡且无特殊关注 $\to$ 准确率；不平衡或关注少数类 $\to$F1/AUC-PR；需要排序能力 $\to$ROC-AUC。