机器学习
第 6 章　线性回归

——万物皆可回归：从一条直线出发，理解一切预测模型的根基

2026 年 3 月 17 日

本章题目导览：你将挑战哪些核心问题？

线性回归是机器学习中最简单也最基础的监督学习算法——理解它，就理解了整个监督学习的核心框架：损失函数、参数求解、梯度下降。本章 7 道题覆盖线性回归的完整体系：

- **Q6-01（概念理解）**：一元 vs 多元线性回归——模型形式、假设条件与应用场景。
- **Q6-02（损失函数）**：MSE 的性质，以及为什么”误差服从正态分布”时，MSE 等价于极大似然估计（MLE）。
- **Q6-03（解析解推导）**：一元线性回归的最小二乘解——手动推导 $\hat{w}$ 和 $\hat{b}$ 的公式，并用具体数据验算。
- **Q6-04（正规方程）**：多元线性回归的矩阵形式与正规方程 $\hat{\boldsymbol{w}} = (X^T X)^{-1} X^T \boldsymbol{y}$ 的推导与计算。
- **Q6-05（梯度下降）**：多元线性回归的梯度推导，手动执行一步参数更新，以及学习率选择问题。
- **Q6-06（代码实践）**：sklearn LinearRegression API 参数解析，以及特征缩放对梯度下降收敛的影响。
- **Q6-07（综合案例）**：广告投放效果预测——完整的建模流程，包括多元回归、评估指标解读与结果分析。

1　第 6 章　线性回归：预测的基础

先建立一个总感觉：线性回归在做什么？

想象你在租房网站上看了 100 套房子，记录了每套的面积（x）和月租（y）。你观察到**面积越大，租金越高**，而且大体上呈正比关系。线性回归就是在问：**能不能找到一条最合适的直线 $y = wx + b$，使它尽可能地”穿过”这 100 个点的中心？**

找到这条线后，给你一套你没看过的新房子，只知道面积，你就能用这条线预测它大概值多少租金。这就是线性回归的全部：**用一条（超）平面来拟合数据，然后用它预测新样本。**

Q6-01 线性回归简介：一元 vs 多元，假设条件

题目描述：

线性回归假设目标变量 y 与输入特征之间存在线性关系，并通过数据学习最优的参数。

问题：

(1) 写出**一元线性回归**和**多元线性回归**的模型形式（数学表达式），并指出两者的联系（多元是一元的什么推广？）。

(2) 填写下表，对比一元和多元线性回归：

对比维度	一元线性回归	多元线性回归
输入特征数	_____	_____
模型参数数	2（w, b）	_____
几何意义	_____	_____
典型应用	面积 → 房价	_____

(3) 线性回归有哪些基本假设？（列举 3 个以上，如线性性、独立性等）违反某个假设会导致什么问题？

(4) 线性回归是否只能建模”直线/平面”关系？能否用线性回归拟合 $y = x^2$ 这种曲线关系？如何实现？（提示：特征变换）

来源溯源：[文档第 6 章 6.1 线性回归简介]

参考答案与详细解析

(1) 模型形式：

- **一元线性回归**：$\hat{y} = wx + b$，只有一个输入特征 x，两个参数 w（斜率）和 b（截距）。
- **多元线性回归**：$\hat{y} = w_1x_1 + w_2x_2 + \cdots + w_px_p + b = \boldsymbol{w}^T\boldsymbol{x} + b$，有 p 个输入特征，$p+1$ 个参数。多元是一元的**高维推广**——从二维平面中的直线，推广到高维空间中的超平面。

(2) 对比表格：

对比维度	一元线性回归	多元线性回归
输入特征数	1 个	p 个（$p \geq 2$）
模型参数数	2（w, b）	$p+1$（$w_1, \ldots, w_p, b$）
几何意义	二维平面上的一条直线	$p+1$ 维空间中的一个超平面
典型应用	面积 → 房价（单因素预测）	面积 + 楼层 + 位置 → 房价（多因素预测）

(3) 线性回归的基本假设：

- **线性性**：y 与各 x_j 之间是线性关系；违反时（实际是非线性）模型系统性偏差，残差有明显规律性。
- **独立性**：样本之间相互独立；违反时（如时间序列数据）标准误差被低估，置信区间失效。
- **同方差性（Homoscedasticity）**：残差的方差在所有 x 水平上一致；违反时参数估计效率降低。
- **正态性**：残差近似正态分布；违反时影响假设检验的可靠性。
- **无多重共线性**：各特征之间不高度相关；违反时系数估计不稳定。

(4) 用线性回归拟合曲线关系：

线性回归中的”线性”指的是**参数的线性**，而非特征的线性。可以通过**特征变换**将非线性问题转化为线性参数问题：将 x 替换为 x^2 作为新特征，则 $\hat{y} = w_1 x^2 + b$ 是关于参数 w_1, b 的线性模型，但关于 x 是二次曲线。这就是**多项式回归**——用线性模型框架拟合非线性关系，只需在特征工程中构造多项式特征即可（sklearn 的 `PolynomialFeatures`）。

Q6-02 损失函数：MSE 的性质与极大似然等价性

题目描述：

线性回归通常用均方误差（MSE）作为损失函数。MSE 不仅是直觉上合理的，在统计学上也有深刻的理论依据。

问题：

(1) 写出均方误差（MSE）和平均绝对误差（MAE）的公式，并从以下四个维度对比两者：

对比维度	MSE	MAE
公式	_____	_____
对异常值敏感性	_____	_____
可微性	_____	_____
物理含义	_____	_____

(2) **极大似然等价性**：假设每个样本的误差 $\varepsilon_i = y_i - \hat{y}_i$ 独立同分布，且服从均值为 0、方差为 σ^2 的正态分布 $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$。

a. 写出条件概率 $P(y_i \mid x_i; \boldsymbol{w})$ 的表达式。

b. 写出 n 个样本的似然函数 $L(\boldsymbol{w})$。

c. 对似然函数取对数后（对数似然），推导出最大化对数似然等价于最小化 MSE 的结论（证明等价性）。

(3) MSE 的最优解是预测值等于真实值均值，而 MAE 的最优解是预测值等于真实值中位数。请解释这两句话的含义，以及它们对异常值处理策略的指导意义。

来源溯源：[文档第 6 章 6.3.1 损失函数]

小白必读：极大似然估计（MLE）是什么概念？

- **核心思想**：在所有可能的参数 $\boldsymbol{w}$ 中，选择使”观测到当前训练数据的概率”最大的那个参数。
- **直觉**：如果真实参数是 $\boldsymbol{w}^*$，那么我们观测到的训练数据应该是在 $\boldsymbol{w}^*$ 下”最有可能”出现的数据。反过来说，给定观测数据，让这些数据出现概率最大的参数，就是最好的参数估计。
- **和 MSE 的联系**：线性回归 MLE 推导出来的参数估计 = 最小化 MSE 的参数——这说明 MSE 有概率论的坚实基础，不只是”随便选的”损失函数。

参考答案与详细解析

(1) MSE vs MAE 对比：

对比维度	MSE	MAE
公式	$\frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2$	$\frac{1}{n}\sum_{i=1}^{n}\lvert\hat{y}_i - y_i\rvert$
异常值敏感性	高度敏感（误差平方放大异常值影响）	相对鲁棒（线性惩罚，不放大异常值）
可微性	处处连续可微，梯度计算简单	在 0 处不可微（绝对值的尖点），需次梯度
物理含义	预测误差的平均平方（方差量纲）	预测误差的平均绝对大小（原始量纲）

(2) 极大似然等价性推导：

a. 因为 $y_i = \boldsymbol{w}^T x_i + b + \varepsilon_i$，$\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$，所以：

$$P(y_i \mid x_i; \boldsymbol{w}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - \hat{y}_i)^2}{2\sigma^2}\right)$$

b. n 个独立样本的似然函数（连乘）：

$$L(\boldsymbol{w}) = \prod_{i=1}^{n} P(y_i \mid x_i; \boldsymbol{w}) = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \exp\left(-\frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{2\sigma^2}\right)$$

c. 对数似然（取 log 将乘积变为求和）：

$$\ell(\boldsymbol{w}) = n \log \frac{1}{\sqrt{2\pi}\sigma} - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

最大化 $\ell(\boldsymbol{w})$ 等价于最小化 $\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$（前一项与 $\boldsymbol{w}$ 无关，$\sigma^2 > 0$）——即**最小化 MSE**。■

等价性的深刻含义

在”误差正态分布”假设下，**最小二乘法（MSE 最小化）= 极大似然估计**。这赋予了线性回归坚实的概率论基础。若误差不是正态分布（如拉普拉斯分布），MLE 将退化为 MAE 最小化——这正是鲁棒回归的理论依据。

(3) 均值 vs 中位数：

MSE 惩罚大误差更重（平方放大），其最优常数预测是均值——均值对所有点的平方偏差之和最小，但易被异常值拉偏。MAE 线性惩罚，其最优常数预测是中位数——中位数对绝对偏差之和最小，对异常值鲁棒。**指导意义**：数据有明显异常值时优先考虑 MAE；数据较干净且希望惩罚大误差时用 MSE。

Q6-03 一元线性回归解析解：推导与手算

题目描述：

对于一元线性回归 $\hat{y} = wx + b$，可以通过对 MSE 损失函数求导并令导数为 0，直接得到最优参数 $\hat{w}$ 和 $\hat{b}$ 的解析公式。

问题：

(1) 设 MSE 为 $J(w,b) = \frac{1}{n}\sum_{i=1}^{n}(wx_i + b - y_i)^2$，对 b 求偏导 $\frac{\partial J}{\partial b} = 0$，推导出 $\hat{b}$ 用 $\hat{w}$、$\bar{x}$、$\bar{y}$ 表示的表达式。

(2) 再对 w 求偏导并代入 $\hat{b}$ 的结果，推导出 $\hat{w}$ 的最终公式：

$$\hat{w} = \frac{\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^{n} x_i^2 - n\bar{x}^2} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

验证两种写法的等价性（选做）。

(3) **手动计算**：给定数据集：

样本	x（广告费，万元）	y（销量，千件）
1	1	3
2	2	5
3	3	6
4	4	8
5	5	9

用公式计算 $\hat{w}$ 和 $\hat{b}$，并写出拟合直线的方程。（提示：$\bar{x} = 3, \bar{y} = 6.2$）

(4) 用第 (3) 题得到的模型，预测广告费为 6 万元时的销量，并说明线性外推（预测范围超出训练数据范围）的风险。

来源溯源：[文档第 6 章 6.3.2 一元线性回归解析解]

参考答案与详细解析

(1) 对 b 求偏导：

$$\frac{\partial J}{\partial b} = \frac{2}{n}\sum_{i=1}^{n}(wx_i + b - y_i) = 0 \implies \sum_{i=1}^{n}(wx_i + b - y_i) = 0 \implies nw\bar{x} + nb - n\bar{y} = 0$$

$$\boxed{\hat{b} = \bar{y} - \hat{w}\bar{x}}$$

(2) 对 w 求偏导并代入 $\hat{b}$：

$$\frac{\partial J}{\partial w} = \frac{2}{n}\sum_{i=1}^{n}(wx_i + b - y_i)x_i = 0$$

代入 $b = \bar{y} - w\bar{x}$：

$$\sum_{i=1}^{n} x_i(wx_i + \bar{y} - w\bar{x} - y_i) = 0 \implies w\sum x_i(x_i - \bar{x}) = \sum x_i(y_i - \bar{y})$$

$$\boxed{\hat{w} = \frac{\sum_{i=1}^{n} x_i(y_i - \bar{y})}{\sum_{i=1}^{n} x_i(x_i - \bar{x})} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}}$$

（最后一步利用了 $\sum(x_i - \bar{x})\bar{y} = \bar{y}\sum(x_i - \bar{x}) = 0$，以及同理对分母的处理。）

(3) 手动计算：

$\bar{x} = 3, \bar{y} = 6.2$。计算各项：

i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
1	-2	-3.2	6.4	4
2	-1	-1.2	1.2	1
3	0	-0.2	0	0
4	1	1.8	1.8	1
5	2	2.8	5.6	4
合计			**15.0**	**10**

$$\hat{w} = \frac{15.0}{10} = 1.5, \quad \hat{b} = 6.2 - 1.5 \times 3 = 6.2 - 4.5 = 1.7$$

拟合直线方程： $\hat{y} = 1.5x + 1.7$

(4) 预测与外推风险：

预测广告费 6 万元时：$\hat{y} = 1.5 \times 6 + 1.7 = 10.7$（千件）。**外推风险：**训练数据范围是 $[1, 5]$，6 万元超出此范围。线性关系只在训练范围内经过验证，实际上销量可能因市场饱和而增长放缓（非线性），线性外推可能严重高估或低估真实销量。

Q6-04 正规方程法：矩阵形式与解析解

题目描述：

多元线性回归可以用矩阵形式优雅地表示，并通过正规方程（Normal Equation）一步求出解析解。

问题：

(1) 将多元线性回归写成矩阵形式 $\hat{\boldsymbol{y}} = X\boldsymbol{w}$。解释矩阵 X、向量 $\boldsymbol{w}$、$\hat{\boldsymbol{y}}$ 各自的维度（假设 n 个样本、p 个特征，且将截距 b 并入 $\boldsymbol{w}$ 中）。

(2) MSE 的矩阵形式为 $J(\boldsymbol{w}) = \frac{1}{n}\|X\boldsymbol{w} - \boldsymbol{y}\|_2^2$。对 $\boldsymbol{w}$ 求梯度并令 $\nabla_{\boldsymbol{w}} J = 0$，推导出正规方程：

$$\hat{\boldsymbol{w}} = (X^T X)^{-1} X^T \boldsymbol{y}$$

(3) 给定以下数据（将截距列并入矩阵）：

$$X = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}, \quad \boldsymbol{y} = \begin{bmatrix} 2 \\ 4 \\ 5 \end{bmatrix}$$

手动计算 $X^T X$、$X^T \boldsymbol{y}$，并用正规方程求 $\hat{\boldsymbol{w}}$。

(4) 正规方程法的**时间复杂度**是多少？当特征数 p 非常大时，为什么更推荐梯度下降法而非正规方程法？

(5) 什么情况下 $X^T X$ 不可逆（奇异）？此时有什么替代方案？

来源溯源：[文档第 6 章 6.3.3 正规方程法]

参考答案与详细解析

(1) 矩阵形式与维度：

将截距 b 并入（在 X 最左列添加全 1 列，$\boldsymbol{w}$ 第一项为 b）：

$$X = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1p} \\ \vdots & & & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{bmatrix}_{n\times(p+1)}, \quad \boldsymbol{w} = \begin{bmatrix} b \\ w_1 \\ \vdots \\ w_p \end{bmatrix}_{(p+1)\times 1}, \quad \hat{\boldsymbol{y}} = X\boldsymbol{w} \in \mathbb{R}^n$$

(2) 正规方程推导：

$$J(\boldsymbol{w}) = \frac{1}{n}(X\boldsymbol{w} - \boldsymbol{y})^T (X\boldsymbol{w} - \boldsymbol{y})$$

对 $\boldsymbol{w}$ 求梯度（利用矩阵求导法则）：

$$\nabla_{\boldsymbol{w}} J = \frac{2}{n} X^T (X\boldsymbol{w} - \boldsymbol{y}) = 0 \implies X^T X\boldsymbol{w} = X^T \boldsymbol{y} \implies \boxed{\hat{\boldsymbol{w}} = (X^T X)^{-1} X^T \boldsymbol{y}}$$

(3) 手动计算：

$$X^T X = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix}$$

$$X^T\boldsymbol{y} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix} \begin{bmatrix} 2 \\ 4 \\ 5 \end{bmatrix} = \begin{bmatrix} 11 \\ 25 \end{bmatrix}$$

$(X^TX)^{-1}$：$\det = 3 \times 14 - 6 \times 6 = 42 - 36 = 6$，

$$(X^TX)^{-1} = \frac{1}{6} \begin{bmatrix} 14 & -6 \\ -6 & 3 \end{bmatrix}$$

$$\hat{\boldsymbol{w}} = \frac{1}{6} \begin{bmatrix} 14 & -6 \\ -6 & 3 \end{bmatrix} \begin{bmatrix} 11 \\ 25 \end{bmatrix} = \frac{1}{6} \begin{bmatrix} 154 - 150 \\ -66 + 75 \end{bmatrix} = \frac{1}{6} \begin{bmatrix} 4 \\ 9 \end{bmatrix} = \begin{bmatrix} 2/3 \\ 3/2 \end{bmatrix}$$

即 $b \approx 0.667$，$w \approx 1.5$，方程为 $\hat{y} = 1.5x + 0.667$。

(4) 时间复杂度与选择：

计算 $(X^TX)^{-1}$ 需要矩阵求逆，时间复杂度为 $O(p^3)$（p 为特征数）。当 p 很大时（如 NLP 中的词袋特征，p 可达数十万），p^3 级别的计算不可接受。梯度下降的每步复杂度为 $O(np)$，总体更适合大 p 场景。

(5) X^TX 不可逆的情况：

特征之间存在**完全多重共线性**（某特征是其他特征的线性组合）；或特征数 $p + 1 > n$（参数多于样本）。替代方案：使用**岭回归正规方程** $\hat{\boldsymbol{w}} = (X^TX + \lambda I)^{-1}X^T\boldsymbol{y}$（L2 正则化保证可逆性）；或用梯度下降法；或 SVD 分解求伪逆。

Q6-05 梯度下降法：推导更新公式与手动迭代

题目描述：

当特征维度很高时，正规方程法代价过高，梯度下降法是更实用的选择。

问题：

(1) 线性回归的 MSE 损失为 $J(\boldsymbol{w}, b) = \frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2$，其中 $\hat{y}_i = \boldsymbol{w}^T x_i + b$。推导出对参数 w_j（第 j 个权重）的梯度更新公式：

$$w_j \leftarrow w_j - \eta \cdot \frac{\partial J}{\partial w_j}$$

写出 $\frac{\partial J}{\partial w_j}$ 和 $\frac{\partial J}{\partial b}$ 的表达式。

(2) **手动执行一步梯度下降**：设一元线性回归，当前参数 $w = 0, b = 0$，学习率 $\eta = 0.1$，训练数据为：

样本	x	y
1	1	2
2	2	4
3	3	6

计算当前预测值、损失、梯度，并执行一步参数更新（使用 BGD）。

(3) 解释**特征缩放对梯度下降收敛的影响**：若两个特征尺度差异很大（如 $x_1 \in [0, 1]$，$x_2 \in [0, 10000]$），损失函数等高线是什么形状？为什么梯度下降会”走之字形”而难以收敛？

(4) 梯度下降法中常见的**局部极小值和鞍点问题**：在线性回归中这是否是问题？在深度学习中呢？

来源溯源：[文档第 6 章 6.3.4 梯度下降法]

参考答案与详细解析

(1) 梯度推导：

$$\frac{\partial J}{\partial w_j} = \frac{2}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i) \cdot x_{ij} \quad \Rightarrow \quad w_j \leftarrow w_j - \eta \cdot \frac{2}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)x_{ij}$$

$$\frac{\partial J}{\partial b} = \frac{2}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i) \quad \Rightarrow \quad b \leftarrow b - \eta \cdot \frac{2}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)$$

(2) 手动一步更新：

当前 $w = 0, b = 0$，各样本预测值 $\hat{y}_i = 0$（全为 0）。误差 $(\hat{y}_i - y_i) = (-2, -4, -6)$。

$$\frac{\partial J}{\partial w} = \frac{2}{3}\sum e_i x_i = \frac{2}{3}[(-2)(1) + (-4)(2) + (-6)(3)] = \frac{2}{3}(-2 - 8 - 18) = \frac{2}{3}(-28) \approx -18.67$$

$$\frac{\partial J}{\partial b} = \frac{2}{3}\sum e_i = \frac{2}{3}(-2 - 4 - 6) = \frac{2}{3}(-12) = -8$$

$$w \leftarrow 0 - 0.1 \times (-18.67) = 1.867$$

$$b \leftarrow 0 - 0.1 \times (-8) = 0.8$$

一步更新后 $w = 1.867, b = 0.8$（真实最优解为 $w = 2, b = 0$，已非常接近）。

(3) 特征缩放对收敛的影响：

若 $x_1 \in [0,1]$，$x_2 \in [0,10000]$，w_2 的微小变化会引起巨大的损失变化，而 w_1 的同样变化只引起微小变化。损失函数等高线在 w_2 方向极扁（椭圆形），在 w_1 方向极宽——使用统一学习率时，梯度在 w_2 方向超调来回震荡（" 之字形"），在 w_1 方向进展极慢，收敛极其缓慢。**特征标准化后**等高线接近圆形，梯度方向直指最优点，收敛快速稳定。

(4) 局部极小值与鞍点：

线性回归的凸性保证

线性回归的 MSE 损失函数对 $\boldsymbol{w}$ 是**严格凸函数**（Hessian 矩阵 $= \frac{2}{n}X^TX$ 半正定），因此**只有一个全局最小值**，梯度下降（设置合适学习率）一定收敛到全局最优，不存在局部极小值和鞍点问题。深度学习中损失函数非凸，理论上存在局部极小值和鞍点，但实践中高维非凸函数中大量的" 局部极小值" 的函数值与全局最优接近，而鞍点才是主要的收敛障碍（梯度接近 0 但不是极小值）。

Q6-06 sklearn API 与特征缩放实践

题目描述：

sklearn 提供了线性回归的完整 API，支持解析法和梯度下降法两种求解方式。

问题：

(1) 阅读以下代码，回答问题：

```python
from sklearn.linear_model import LinearRegression, SGDRegressor
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline
import numpy as np

# 方法一：正规方程（解析法）
lr = LinearRegression(fit_intercept=True, copy_X=True)
lr.fit(X_train, y_train)
print(f"系数：{lr.coef_}, 截距：{lr.intercept_}")
print(f"R²：{lr.score(X_test, y_test):.4f}")

# 方法二：SGD（梯度下降法）
pipe = Pipeline([
    ('scaler', StandardScaler()),
    ('sgd', SGDRegressor(loss='squared_error', max_iter=1000,
                         tol=1e-3, learning_rate='adaptive',
                         eta0=0.01, random_state=42))
])
pipe.fit(X_train, y_train)

```

a. `LinearRegression` 的 `fit_intercept=True` 有什么作用？设为 `False` 时模型会变成什么形式？

b. `lr.score(X_test, y_test)` 返回的是什么指标？公式是什么？

c. 为什么 `SGDRegressor` 前面加了 `StandardScaler()`，而 `LinearRegression` 不需要？

d. `Pipeline` 的作用是什么？在预测时，它自动对新数据做了什么？

(2) `SGDRegressor` 中 `learning_rate='adaptive'` 是什么策略？与固定学习率相比有什么优势？

(3) 线性回归的 `normalize` 参数（旧版 sklearn）已被弃用，应改用什么方式进行特征归一化？写出推荐的替代写法。

来源溯源：[文档第 6 章 6.2 API 使用 / 6.3.4 梯度下降法 API]

参考答案与详细解析

(1) 代码问题：

a. `fit_intercept=True`（默认）：模型会自动拟合截距 b，即在特征矩阵中隐式添加全 1 列。设为 `False` 时，模型变为**过原点的线性回归** $\hat{y} = \boldsymbol{w}^T x$（截距强制为 0），适用于已知数据必须过原点的场景（如物理定律），但大多数情况下不应设为 False。

b. `lr.score()` 返回**决定系数** R^2，公式：$R^2 = 1 - \dfrac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$，越接近 1 越好（最大为 1，可为负）。

c. `LinearRegression` 使用正规方程求解，是纯粹的数学计算（矩阵运算），特征尺度不影响解的正确性。`SGDRegressor` 使用梯度下降，特征尺度影响梯度大小和收敛速度，必须标准化使各特征梯度在同一量级，否则收敛极慢。

d. `Pipeline` 将多个处理步骤链接为一个整体，`fit` 时依次训练每步，`predict` 时自动对新数据先 `transform`（不 `fit`）再传给下一步。这自动防止了数据泄漏（scaler 只在训练集 fit 一次）。

(2) `learning_rate='adaptive'`：

自适应学习率策略：初始学习率为 `eta0`，当发现当前更新后损失没有减小时，自动将学习率**除以 5**（衰减），逐步缩小步长。与固定学习率相比：不需要手动调节衰减，自动在初期快速收敛、后期精细调整，更稳健地处理不同曲率的损失面。

(3) 替代 `normalize` 的写法：

```python
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline

# 推荐写法：用Pipeline显式组合标准化和模型
model = Pipeline([
    ('scaler', StandardScaler()),
    ('lr', LinearRegression())
])
model.fit(X_train, y_train)
y_pred = model.predict(X_test)

```

Q6-07 综合案例：广告投放效果预测

题目描述：

某公司收集了 200 条广告数据，包含三种渠道的投放费用（TV、Radio、Newspaper，单位：千美元）和对应的销量（Sales，单位：千件）。目标是建立多元线性回归模型，预测给定广告预算下的销量。

问题：

(1) 写出该问题的多元线性回归模型形式（用 TV、Radio、Newspaper 作为变量名）。

(2) 下面是建模代码框架，请填写缺失部分并回答问题：

```python
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error, mean_squared_error,
    r2_score
import numpy as np

df = pd.read_csv('advertising.csv')
X = df[['TV', 'Radio', 'Newspaper']]
y = df['Sales']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)

model = LinearRegression()
model.fit(X_train, y_train)
y_pred = model.predict(X_test)

# 评估
mae  = mean_absolute_error(y_test, y_pred)
mse  = mean_squared_error(y_test, y_pred)
rmse = np.sqrt(mse)
r2   = r2_score(y_test, y_pred)

print(f"系数: {dict(zip(X.columns, model.coef_))}")
print(f"截距: {model.intercept_:.4f}")
print(f"MAE={mae:.4f}, RMSE={rmse:.4f}, R²={r2:.4f}")

```

假设输出为：

- 系数：`{TV: 0.0458, Radio: 0.1885, Newspaper: -0.0010}`
- 截距：`2.9389`
- 输出：`MAE=1.4632, RMSE=1.8940, R²=0.8992`

a. 系数如何解释？TV 系数 0.0458 意味着什么？

b. Newspaper 系数为负（-0.0010），这说明什么？应该直接删掉 Newspaper 特征吗？

c. $R^2 = 0.8992$ 怎么解读？这个模型表现如何？

d. 如果想预测 TV=200、Radio=50、Newspaper=10 时的销量，写出计算过程。

参考答案与详细解析

(1) 模型形式：

$$\widehat{\text{Sales}} = w_1 \cdot \text{TV} + w_2 \cdot \text{Radio} + w_3 \cdot \text{Newspaper} + b$$

(2) 输出解读：

a. **TV 系数 0.0458**：在 Radio 和 Newspaper 投入不变的情况下，TV 广告费每增加 1 千美元，预测销量**增加 0.0458 千件（约 46 件）**。这是偏效应——控制其他变量不变时的单变量贡献。

b. Newspaper 系数 ≈ -0.001 且绝对值极小，说明在控制 TV 和 Radio 投入后，Newspaper 对销量几乎没有独立贡献（可能与 Radio 相关，多重共线性使其系数变负）。**不应直接删掉**，应先做相关分析、方差膨胀因子（VIF）检验，确认多重共线性后再决定是否删除或用正则化处理。

c. $R^2 = 0.8992$ 说明模型解释了测试集中**约 89.9% 的销量方差**，未被解释的部分约 10%。MAE=1.46 千件说明平均预测误差约 1460 件，RMSE=1.89 千件——总体来说这是一个表现不错的模型。

d. 预测计算：

$$\hat{y} = 0.0458 \times 200 + 0.1885 \times 50 + (-0.001) \times 10 + 2.9389$$

$$= 9.16 + 9.425 - 0.01 + 2.9389 = \mathbf{21.51}\text{（千件）}$$

(3) 进一步提升方向：

- **特征工程**：构造交互特征（如 TV × Radio），因为广告渠道之间可能有协同效应；
- **多项式特征**：添加 TV^2 等非线性项，若销量与广告费呈非线性关系（如边际递减）；
- **正则化**：用 Ridge 或 Lasso 回归处理 Newspaper 的多重共线性问题；
- **删除冗余特征**：用 VIF 检验确认高度共线的特征后删除，减少噪声；
- **集成模型**：尝试 XGBoost、随机森林等非线性模型，不假设线性关系。

现实应用场景

线性回归在工业中的广泛应用：

金融领域（利率预测、信用评分）、营销领域（广告 ROI 预测、价格弹性分析）、工程领域（设备故障预测、能耗估计）、医疗领域（药物剂量-反应关系、流行病学研究）。尽管深度学习的流行，在数据量有限、需要可解释性、或问题确实接近线性的场景中，线性回归（或其正则化版本岭/Lasso 回归）仍然是工业界首选的基线方法之一。

2 本章小结

- **两种求解方法**：正规方程（解析法，$O(p^3)$，p 小时用）vs 梯度下降（迭代法，$O(np)$ 每步，p 大时用）。
- **MSE 的统计根基**：误差正态分布假设下，MSE 最小化 = 极大似然估计——不是随意选的损失。
- **线性回归是凸优化**：唯一全局最优，梯度下降保证收敛，不存在局部极小值困扰。
- **梯度下降必须先标准化**：特征尺度差异导致”之字形”收敛——这是一个工程铁律。
- **线性回归的线性是参数的线性**：通过多项式特征变换，可以拟合非线性关系，灵活性远超直觉。